


- **Autheurs** : Axel Coulet et Nathan Ruelle
- **Groupe** : Praxis 2
- **Département** : Science des Données
- **Établissement** : Université Sorbonne Paris Nord – IUT de Villeuniversité

Date : Juin 2025

Analyse exploratoire des données


1. Proportion de tumeurs malignes et bénignes

Répartition des types de tumeurs




Parmi l'ensemble des cas observés, 63 % des tumeurs sont bénignes contre 37 % de tumeurs malignes. Cela suggère qu'une majorité des diagnostics ne correspondent pas à des formes cancéreuses agressives.

2. Histogramme du rayon moyen des tumeurs













L'histogramme du rayon moyen présente une distribution unimodale centrée autour de 13, ce qui évoque une forme proche de la loi normale. La majorité des valeurs sont comprises entre 10 et 15. Au-delà de 15, les cas deviennent plus rares, ce qui correspond à des tumeurs de plus grande taille.

3. Histogramme du rayon moyen selon le type de tumeur



L'histogramme révèle une distinction nette autour d'un rayon de 15 : les tumeurs de rayon inférieur sont majoritairement bénignes, tandis que celles dont le rayon dépasse 15 sont le plus souvent malignes. Cela indique une corrélation entre la taille de la tumeur (rayon) et son caractère malin.

4. Histogramme des paramètres des tumeurs



5. Analyse des variables permettant de prédire le type de tumeur

Radius (rayon) : Cette variable montre une forte capacité discriminante. Les tumeurs bénignes présentent majoritairement un rayon compris entre 4 et 15, tandis que les tumeurs malignes se situent plutôt entre 14 et 25. Cela suggère qu'un rayon élevé est associé à une probabilité plus forte de malignité, ce qui est cohérent avec le fait que les tumeurs cancéreuses tendent à être plus volumineuses.

Perimeter (périmètre) : La distribution du périmètre suit une tendance similaire à celle du rayon. Les tumeurs bénignes ont un périmètre généralement inférieur à 100, tandis que les tumeurs malignes dépassent souvent cette valeur, atteignant jusqu'à 180. Cela renforce l'idée qu'une tumeur plus étendue (grande taille) est plus souvent maligne.

Area (aire) : Comme pour le rayon et le périmètre, la surface est une variable bien discriminante. Les tumeurs bénignes se concentrent entre 100 et 650, alors que les malignes s'étendent entre 650 et 2000. Cette progression continue d'indiquer une corrélation entre la taille de la tumeur et son caractère malin.

Compactness (compacité) : Cette variable montre un certain pouvoir discriminant. Les tumeurs bénignes se situent principalement entre 0.04 et 0.12, alors que les tumeurs malignes sont plus fréquentes entre 0.12 et 0.30. Cela indique une certaine pertinence de cette variable pour la classification.


Concavity (concavité) : C'est une des variables les plus discriminantes. Les tumeurs bénignes ont des valeurs proches de 0 à 0.1, avec un pic entre 0 et 0.05, tandis que les malignes sont très présentes au-delà de 0.1. Cela reflète des différences morphologiques significatives entre les deux types.

Concave points (nombre de points concaves) : Comme la concavité, cette variable est fortement discriminante. Les tumeurs bénignes sont majoritairement comprises entre 0 et 0.05, tandis que les malignes se situent entre 0.05 et 0.2. Ce critère est donc utile pour différencier les types de tumeurs.

Pourquoi toutes les variables ne sont pas discriminantes :

Les variables liées à la taille (`radius` , `perimeter` , `area`) présentent une forte capacité à distinguer les types de tumeurs : les valeurs sont systématiquement plus élevées pour les tumeurs malignes. La concavité et les points concaves montrent également un excellent pouvoir discriminant, avec des distributions bien séparées selon le diagnostic. En revanche, des variables comme la texture, la finesse ou la symétrie montrent des distributions similaires entre tumeurs bénignes et malignes. Elles n'offrent donc pas un critère fiable de distinction.

6. Nuage de points : texture moyenne vs rayon moyen




Analyse du nuage de points : interprétation visuelle et corrélation

La corrélation entre le rayon moyen et la texture moyenne est de : 32.38 %


La corrélation entre le rayon et la texture est modérée (32 %), ce qui indique un lien partiel. La texture ne semble pas dépendre fortement de la taille de la tumeur, ce qui limite son utilité comme variable de prédiction.

Les tumeurs de rayon supérieur à 15 sont majoritairement malignes. Celles dont le rayon est compris entre 8 et 15 sont généralement bénignes. Cela confirme que le rayon est une variable pertinente pour la classification. En revanche, la texture est peu informative, car sa distribution reste dispersée quel que soit le type de tumeur.

7. Validation graphique des variables discriminantes




La corrélation entre le rayon moyen et la compacité moyenne est de : 50.61 %



La corrélation entre le rayon moyen et la concavité moyenne est de : 67.68 %

Rayon moyen vs Nombre moyen de points concaves selon le type de tumeur



La corrélation entre le rayon moyen et les points concaves est de : 82.25 %

Les variables `concavity_mean` et `concave points_mean` présentent des corrélations respectives de 67 % et 82 % avec `radius_mean`, ce qui confirme leur fort pouvoir discriminant. La compacité affiche une corrélation plus modérée (50 %), ce qui indique une contribution moins nette à la séparation des classes. Le périmètre et l'aire n'ont pas été retenus car ils sont redondants avec le rayon, du fait de leur relation géométrique directe.

8. Méthode quantitative de classification

Analyse des Variables Utilisées dans la Règle de Prédiction

Objectif

L'objectif est d'évaluer la pertinence des trois variables utilisées dans une règle simple de prédiction du type de tumeur (bénigne ou maligne), en les comparant à l'ensemble des autres variables du jeu de données.

Les variables utilisées dans la règle sont :


- `area_worst`
- `concave points_worst`
- `radius_worst`

L'analyse se base sur la **corrélation avec la variable cible** `diagnosis` (0 = bénin, 1 = malin).

Méthode

1. Convertir la variable `diagnosis` en valeurs numériques (0 pour bénin, 1 pour malin).
 2. Calculer la **corrélation de Pearson** entre chaque variable numérique et `diagnosis`.
 3. Trier les variables par corrélation décroissante.
 4. Visualiser les résultats à l'aide d'un graphique en barres horizontales.
-

Corrélation de chaque variable avec le diagnostic (1 = tumeur maligne)



Top 5 des variables les plus corrélées avec le diagnostic :

```
concave points_worst    0.793566
perimeter_worst         0.782914
concave points_mean     0.776614
radius_worst            0.776454
perimeter_mean          0.742636
Name: diagnosis, dtype: float64
```

Résultats

L'analyse montre que `concave points_worst` présente la plus forte corrélation avec la variable cible. Les variables `radius_worst` et `area_worst` sont également parmi les cinq premières. À l'inverse, des variables comme `smoothness_mean`, `symmetry_mean` ou `fractal_dimension_mean` ont un pouvoir discriminant limité.

Conclusion

Les variables `area_worst`, `concave points_worst` et `radius_worst` sont **pertinentes et justifiées** pour une règle simple de prédiction, car :

- Elles sont parmi les variables **les plus corrélées** à la cible.
- Elles permettent de **séparer efficacement** les tumeurs bénignes des tumeurs malignes.
- Leur choix repose sur des **résultats statistiques clairs et mesurables**.

Cette analyse confirme donc la **qualité du choix initial**.

Il serait possible d'envisager une **amélioration de la règle** en testant d'autres variables également très

```
Run 01 - Taux de réussite : 100.0%
Run 02 - Taux de réussite : 100.0%
Run 03 - Taux de réussite : 100.0%
Run 04 - Taux de réussite : 90.0%
Run 05 - Taux de réussite : 90.0%
Run 06 - Taux de réussite : 90.0%
Run 07 - Taux de réussite : 90.0%
Run 08 - Taux de réussite : 90.0%
Run 09 - Taux de réussite : 100.0%
Run 10 - Taux de réussite : 100.0%
Run 11 - Taux de réussite : 90.0%
Run 12 - Taux de réussite : 90.0%
Run 13 - Taux de réussite : 100.0%
Run 14 - Taux de réussite : 100.0%
Run 15 - Taux de réussite : 100.0%
Run 16 - Taux de réussite : 90.0%
Run 17 - Taux de réussite : 90.0%
Run 18 - Taux de réussite : 100.0%
Run 19 - Taux de réussite : 90.0%
Run 20 - Taux de réussite : 90.0%
```

Taux de réussite moyen sur 20 runs : 94.5%

Analyse de la règle de prédiction

Objectif

Développer une règle simple pour estimer si une tumeur est bénigne (`0`) ou maligne (`1`), à partir de trois variables : `area_worst`, `concave points_worst` et `radius_worst`.

Méthode

- Si **au moins une** des conditions suivantes est remplie :
 - `area_worst > 1000`

- `concave points_worst > 0.15`

- `radius_worst > 17`

→ alors la tumeur est prédite comme **maligne**, sinon **bénigne**.

- La règle a été testée sur **20 échantillons aléatoires** de 10 observations.

Résultats


- **Taux de réussite moyen : 94.5 %**
- Très bonne performance pour une règle experte simple
- Les variables choisies sont **empiriquement pertinentes d'un point de vue morphologique** : tumeurs plus grandes ou plus irrégulières → plus souvent malignes

Limites

- Échantillons de petite taille (n=10), ce qui peut introduire une variabilité importante.
- Une validation croisée sur un jeu de test complet améliorerait la robustesse de l'évaluation.

Mise en évidence de liaisons entre les variables

1. Matrice de corrélation entre variables morphologiques



Analyse de la matrice de corrélation

Description

La matrice ci-dessous présente les coefficients de corrélation de Pearson entre cinq variables statistiques sélectionnées :

- radius_mean
- perimeter_mean
- area_mean
- compactness_mean
- concavity_mean

Corrélations très fortes (≥ 0.99)

- radius_mean — perimeter_mean ≈ 1.00
- radius_mean — area_mean ≈ 0.99
- perimeter_mean — area_mean ≈ 0.99

Ces trois variables sont géométriquement liées :

- Le périmètre est proportionnel au rayon (périmètre $\approx 2 \cdot \pi \cdot r$)
- L'aire est proportionnelle au carré du rayon (aire $\approx \pi \cdot r^2$)

Il est donc logique que leurs corrélations soient quasi parfaites.

Corrélations fortes (entre 0.7 et 0.88)

- `concavity_mean` — `compactness_mean` $\approx$ **0.88**
- `concavity_mean` — `perimeter_mean` $\approx$ **0.72**
- `concavity_mean` — `radius_mean` $\approx$ **0.68**
- `concavity_mean` — `area_mean` $\approx$ **0.69**

Ces liens indiquent que la forme des tumeurs (concavité) est partiellement influencée par leur taille.


Corrélations modérées ($\approx$ 0.50 à 0.56)

- `compactness_mean` — `radius_mean` $\approx$ **0.51**
- `compactness_mean` — `perimeter_mean` $\approx$ **0.56**
- `compactness_mean` — `area_mean` $\approx$ **0.50**


La compacité reste relativement indépendante de la taille globale : elle exprime surtout l'irrégularité des contours.

2. Ajustement linéaire entre variables corrélées

compactness_mean ~ radius_mean ($R^2 = 0.256$)



concavity_mean ~ radius_mean ($R^2 = 0.458$)



concavity_mean ~ compactness_mean ($R^2 = 0.780$)






Tableau récapitulatif :

	Variable X	Variable Y	Coefficient	R ²
0	radius_mean	compactness_mean	0.008	0.256
1	radius_mean	concavity_mean	0.015	0.458
2	compactness_mean	concavity_mean	1.333	0.780

Interprétation du coefficient de détermination (R^2)

Nous avons sélectionné les variables `compactness_mean`, `concavity_mean` et `radius_mean`. Les autres variables (comme `area_mean` ou `perimeter_mean`) ont été écartées car elles sont fortement corrélées à `radius_mean` mais aussi, afin d'alléger le nombre de graphique.

Relation entre `radius_mean` et `compactness_mean`


Le coefficient de détermination R^2 est d'environ **0.25**. Cela signifie que le rayon explique peu la variabilité de la compacité. Ces deux variables décrivent des aspects morphologiques différents.

Relation entre `radius_mean` et `concavity_mean`

$R^2 \approx 0.45$ indique une corrélation modérée. Les tumeurs plus grandes tendent à être plus concaves, mais la relation reste partielle. La concavité conserve un pouvoir explicatif propre.

Relation entre `compactness_mean` et `concavity_mean`

Avec $R^2 \approx 0.78$, ces deux variables sont fortement corrélées. Elles capturent toutes deux l'irrégularité du contour de la tumeur. Il peut être pertinent de n'en conserver qu'une pour éviter la redondance dans un modèle prédictif.



Étude des résidus

Les résidus mesurent l'écart entre les valeurs observées et les valeurs prédites par le modèle. Leur analyse est essentielle pour valider les hypothèses de la régression linéaire.

- Pour `compactness_mean ~ radius_mean`, les résidus sont très dispersés, sans tendance claire. La relation est faible et probablement non linéaire.
- Pour `concavity_mean ~ radius_mean`, on observe une légère structure dans les résidus, suggérant un lien partiellement non linéaire.

- Pour `concavity_mean ~ compactness_mean`, les résidus sont bien centrés et répartis aléatoirement. L'hypothèse d'un modèle linéaire est ici bien respectée.

Ainsi, seule la dernière régression (concavité sur compacité) peut être considérée comme fiable pour un ajustement linéaire. Les autres relations nécessiteraient soit un modèle non linéaire, soit une transformation des données.

Conclusion générale

Ce projet d'analyse de données biomédicales a permis de mettre en évidence plusieurs éléments clés pour la classification des tumeurs en fonction de leur nature (bénigne ou maligne).

Résumé des observations

- Les variables les plus discriminantes sont `radius_mean`, `concavity_mean`, `concave points_mean`, ainsi que leurs versions "worst".
- Les relations entre ces variables ont été confirmées à la fois graphiquement (nuages de points) et statistiquement (corrélations élevées).
- Des variables comme `texture_mean`, `symmetry_mean` ou `fractal_dimension_mean` se sont révélées peu utiles pour différencier les tumeurs.

Résultat de la règle de prédiction

Une règle simple fondée sur trois seuils (`area_worst`, `radius_worst`, `concave points_worst`) atteint un taux de réussite moyen de **94,5 %** sur plusieurs échantillons aléatoires. Ce résultat montre qu'un modèle basé sur une logique experte bien pensée peut déjà fournir une performance robuste.