

CR

SÉRIE CHRONOLOGIQUE

Date

25 janvier 2026

Auteurs

Axel COULET

Igor MILOSEVIC

Sommaire

1	Introduction	3
1.1	Partie 1 : Prévisions par décomposition	3
1.2	Partie 2 : Étude du modèle ARIMA	3
2	Analyse de séries chronologiques	3
2.1	Environnement Technique et Outils	3
2.2	Choix de la série et justification	4
2.3	Choix du modèle	4
2.4	Extraction de la composante saisonnière	6
2.5	La série Corrigée des Variations Saisonnières (CVS)	8
2.6	Calcul du LES	10
2.7	Calcul du LED	12
2.8	Ajustement par la méthode des Moindres Carrés	14
3	Prédiction à partir des modèles	16
3.1	Prévisions 2024 : Modèle de Lissage Exponentiel Simple (LES)	16
3.2	Prévisions 2024 : Modèle de Lissage Exponentiel Double (LED)	18
3.3	Prévisions 2024 : Méthode des Moindres Carrés (Tendance Linéaire)	20
3.4	Synthèse et comparaison des modèles de prévision	22
4	Partie 2 : Étude du modèle ARIMA	24
4.1	Analyse de la stationnarité et Différenciation	24
4.2	Identification des ordres (p et q)	25
4.3	Estimation et Sélection du meilleur modèle	25
4.4	Validation du Modèle ARIMA (1,1,1)	26
4.5	Conclusion Générale	27

I 1 Introduction

Ce rapport présente notre travail réalisé dans le cadre de la SAé « Séries chronologiques ». L'objectif principal de ce projet est d'apprendre à prévoir l'évolution future de données qui varient selon les saisons. Pour cela, nous avons exploré deux approches différentes.

1.1 Partie 1 : Prévisions par décomposition

Dans cette première partie, nous sommes partis d'une série de données réelles (issue de l'INSEE) que nous avons choisie pour sa saisonnalité marquée. Le but est de décomposer cette série pour isoler les variations saisonnières et obtenir une courbe « nettoyée » (série CVS). Nous avons ensuite réalisé des prévisions en utilisant trois méthodes de calcul:

- Le lissage exponentiel simple.
- Le lissage exponentiel double.
- L'ajustement de la tendance (méthode des moindres carrés).

Ces manipulations ont été faites sur tableur et avec du code Python pour analyser les résultats.

1.2 Partie 2 : Étude du modèle ARIMA

La seconde partie se concentre sur une méthode plus avancée : le modèle ARIMA. Nous nous sommes appuyés sur une étude de cas existante (données boursières) pour en comprendre le fonctionnement. Au-delà de l'application technique du code, nous avons cherché à expliquer clairement les étapes de l'analyse. Enfin, nous avons comparé les performances de deux modèles spécifiques (ARIMA 1,1,1 et ARIMA 1,1,2) pour voir lequel offrait les meilleures prédictions.

I 2 Analyse de séries chronologiques

2.1 Environnement Technique et Outils

L'ensemble de cette étude a été réalisé en langage **Python**, standard actuel pour l'analyse de données. Pour mener à bien le traitement des séries chronologiques, la visualisation et la modélisation, nous nous sommes appuyés sur les bibliothèques suivantes :

- **Pandas** : Utilisée pour la structuration et la manipulation des données. Elle nous a permis de gérer l'indexation temporelle (dates), de réaliser le nettoyage du dataset, ainsi que les différents calcul et d'effectuer les opérations de **resampling** (rééchantillonnage) nécessaires à l'analyse mensuelle.
- **Matplotlib** : Employée pour la visualisation graphique. C'est grâce à elle que nous avons généré les courbes d'évolution, les profils saisonniers et les graphiques comparatifs de prévision, essentiels à l'interprétation des résultats.
- **Scikit-learn (sklearn)** : Sollicitée pour la partie modélisation déterministe et l'évaluation. Nous l'avons utilisée pour implémenter la régression linéaire (méthode des Moindres Carrés) et optimiser certains paramètres.

2.2 Choix de la série et justification

Pour cette première partie, nous avons choisi d'analyser une série chronologique portant sur le nombre de mariages célébrés par mois.

Bien que le jeu de données initial couvre la période de 1994 à 2023, nous avons décidé de restreindre notre étude à la décennie 2014-2023. Ce choix a pour but de travailler sur des données plus représentatives des mœurs et des comportements actuels, en évitant les tendances trop anciennes qui ne sont plus pertinentes aujourd'hui.

Notre hypothèse de départ est que cette série présente une forte saisonnalité. En effet, il semble logique d'observer un pic de mariages durant la période estivale (été) par rapport à la période hivernale. L'objectif des analyses suivantes est de confirmer mathématiquement cette intuition, de corriger ces variations saisonnières, puis d'établir des prévisions pour les mois à venir.

2.3 Choix du modèle

Pour déterminer si la saisonnalité est de nature additive ou multiplicative, nous avons réalisé deux analyses graphiques distinctes.

2.3.1 Test de corrélation Moyenne / Écart-type

Nous avons calculé pour chaque année la moyenne mensuelle des mariages (axe des abscisses) et l'écart-type correspondant (axe des ordonnées). Dans un modèle additif, l'écart-type (la variabilité) devrait rester constant quelle que soit la moyenne. Or, le nuage de points ci-dessous montre une tendance croissante : les années où le nombre moyen de mariages est plus élevé présentent une plus forte volatilité. Cette dépendance entre le niveau de la série et son amplitude est caractéristique d'un **modèle multiplicatif**.




Fig. 1 — Relation entre la moyenne annuelle et l'écart-type

2.3.2 Analyse de la superposition des cycles annuels

Nous avons ensuite superposé les courbes de chaque année sur un même graphique pour observer leur parallélisme. Si le modèle était additif, les courbes seraient globalement parallèles (l'écart entre l'été et l'hiver serait toujours le même, par exemple +500 mariages). Ici, l'observation graphique suggère que les courbes ne sont pas strictement parallèles : l'amplitude des pics d'été a tendance à s'intensifier ou se réduire proportionnellement au niveau global de l'année. Ce manque de parallélisme strict confirme le choix d'une décomposition **multiplicative**.




Fig. 2 — Superposition des profils saisonniers par année

2.3.3 Conclusion

L'absence de parallélisme strict et la corrélation observée entre la moyenne et l'écart-type nous conduisent à retenir le modèle multiplicatif, qui se définit par l'équation suivante :

$$\text{Observation}_t = \text{Tendance}_t \times (1 + \text{Saison}_t) \times (1 + \text{Erreur}_t)$$

Dans cette formulation, les termes « **Saison** » et « **Erreur** » agissent comme des coefficients multiplicateurs (pourcentages) qui viennent moduler le niveau moyen défini par la tendance.

2.4 Extraction de la composante saisonnière

Pour isoler et quantifier la saisonnalité, nous avons procédé en deux étapes : d'abord l'estimation de la tendance-cycle par lissage, puis le calcul des coefficients mensuels. Nous avons choisi un ordre 12 pour la moyenne mobile centrée car les années sont divisées en 12 mois dans le dataset.

2.4.1 Estimation de la tendance par Moyenne Mobile

Pour isoler la tendance de fond (en bleu) de la série brute (en gris), nous avons appliqué une **Moyenne Mobile Centrée (MMC)**.

Justification de l'ordre 12 :

Ce paramètre n'est pas arbitraire, il découle directement de la périodicité mensuelle de nos données. Puisque le cycle des mariages se répète tous les ans, une fenêtre glissante de 12 mois est la seule qui permet d'englober un cycle complet à chaque calcul.

Mécaniquement, chaque moyenne inclut ainsi exactement un mois de chaque type (un janvier, un juillet, etc.). Par conséquent, les pics d'activité estivaux compensent mathématiquement les creux hivernaux. Cette opération neutralise totalement l'effet saisonnier pour ne laisser apparaître que la tendance de fond.




Fig. 3 — Lissage de la série par Moyenne Mobile Centrée (ordre 12)

On observe que la courbe rouge traverse les données brute en leurs centres. L'écart vertical entre la donnée réelle (grise) et la moyenne lissée (rouge) correspond précisément à l'impact de la saison. Dans notre modèle multiplicatif, cet écart se calcule par le ratio :

$$\text{Coeffs} = \frac{\text{Valeur Réelle}}{\text{Moyenne Mobile}}$$

2.4.2 Analyse des Coefficients Saisonniers

En moyennant ces ratios pour chaque mois de l'année sur la période 2014-2023, nous obtenons les coefficients saisonniers définitifs. Nous avons vérifié que leurs sommes est strictement égale à 12 pour valider le modèle.




Fig. 4 — Profil saisonnier moyen des mariages

Les tableaux ci-dessous détaille ces valeurs :

Mois	Coeffs Brut	Coeffs Corrigés
1	0.35082002	0.35082112
2	0.44938406	0.44938548
3	0.46614195	0.46614341
4	0.72217341	0.72217568
5	1.10833783	1.10834131
6	1.70284263	1.70284798
7	1.84390522	1.84391101
8	1.66172305	1.66172827
9	1.67364338	1.67364863
10	0.95993985	0.95994286
11	0.46901602	0.46901749
12	0.59203489	0.59203675

Tableau 1 — Coefficients Saisonniers

Metrique	Valeur
Somme Brute (Calculée)	11.999962
Somme Corrigée (Cible = 12)	12
Coefficient Correcteur	1.000003

Tableau 2 — Vérification des Coefficients

2.4.3 Interprétation :

L'analyse des coefficients confirme l'extrême saisonnalité de l'activité :

- **Le creux hivernal** : En janvier, l'activité est à **46%** de son niveau moyen théorique.
- **Le pic estival** : En juillet, l'activité bondit à **173%** (soit un facteur x3.7 par rapport à janvier).

Ce profil en cloche très marqué dictera la forme de nos futures prévisions.

2.5 La série Corrigée des Variations Saisonnnières (CVS)

Après avoir validé nos coefficients saisonniers, nous les avons appliqués à la série brute pour éliminer les fluctuations périodiques.

2.5.1 Méthode de calcul

Dans notre modèle multiplicatif, la correction s'obtient en divisant la valeur brute par le coefficient saisonnier du mois correspondant :

$$\text{Valeur Désaisonnalisée}_t = \frac{\text{Valeur Brute}_t}{\text{Coefficient Saisonnier}_t}$$

Cette opération a pour but de répondre à la question : « Combien y aurait-il eu de mariages ce mois-ci si c'était un mois "neutre", sans effet de saison ? »

2.5.2 Analyse graphique

Le graphique ci-dessous superpose la série brute initiale et la série CVS obtenue.




Fig. 5 — Comparaison Série Brute vs Série CVS (2014-2023)

2.5.3 Interprétation des résultats :

L'efficacité de la désaisonnalisation est visible :

- **Lissage des pics** : La courbe CVS (lissée) ne présente plus les oscillations régulières extrêmes de la courbe brute. Les pics de juillet et les creux de janvier ont été gommés.
- **Mise en évidence de la tendance-cycle** : La courbe CVS révèle la véritable dynamique de fond. On distingue beaucoup mieux les évolutions réelles.
- **L'anomalie 2020** : La chute brutale observée en 2020 (crise COVID) apparaît désormais de manière très nette et isolée, sans être noyée dans les variations habituelles de l'année.

La série CVS nous servira de base « propre » pour effectuer nos prévisions de tendance dans la section suivante.

2.6 Calcul du LES

2.6.1 Optimisation du paramètre de lissage (β)

Pour calibrer notre modèle de Lissage Exponentiel Simple (LES), nous avons procédé en deux temps : une recherche automatique de l’optimum mathématique, suivie d’une correction empirique.

2.6.1.1 Approche théorique : Minimisation de l’erreur (RMSE)

Dans un premier temps, nous avons utilisé un algorithme d’optimisation (bibliothèque sklearn / boucle de recherche) pour trouver la valeur de β qui minimise l’erreur quadratique moyenne (RMSE) sur la série CVS.

Résultat obtenu : L’algorithme a convergé vers un $\beta \approx 0.01$.


Analyse critique :

Avec un β aussi faible, la formule de lissage s’interprète ainsi :

$$\text{Niveau Calculé} = 0.01 \times \text{Mémoire du Passé} + 0.99 \times \text{Observation Actuelle}$$

Cela signifie que le modèle accorde **99% de poids à la dernière observation**. En conséquence, la courbe lissée se contente de recopier presque parfaitement la série CVS, incluant tout son bruit et ses irrégularités. Bien que cela minimise mathématiquement l’erreur immédiate, cela n’a aucune valeur prédictive car aucun lissage réel n’est effectué.

Nous avons donc rejeté ce paramètre « optimal » au sens strict.



(a) Visualisation du LES

Parametre	Valeur
Beta	0.01
Erreur (RMSE)	36.216

(b) Score meilleur β

Fig. 6 — Échec du lissage avec l’optimum théorique ($\beta = 0.01$)




Fig. 7 — Reconstruction avec $\beta = 0.01$: Le modèle copie le bruit

2.6.1.2 Approche retenue : Choix empirique ($\beta = 0.8$)

Pour obtenir un véritable effet de lissage capable de dégager la tendance de fond, nous avons fixé arbitrairement le paramètre à $\beta = 0.8$.

Niveau Calculé = $0.8 \times \text{Mémoire du Passé} + 0.2 \times \text{Observation Actuelle}$

Ce réglage force le modèle à s'appuyer majoritairement (80%) sur l'historique de la série, ce qui gomme les variations erratiques mensuelles.

Performances du modèle retenu :

Le tableau ci-dessous présente les erreurs associées à ce choix. Bien qu'elles soient mathématiquement plus élevées que précédemment, le modèle est beaucoup plus robuste.

Parametre	Valeur
Erreur Moyenne (EM)	74.527
Erreur Quadratique Moyenne (EQM)	12324314.161
Erreur Absolue Moyenne (EAM)	2445.613

Tableau 4 — Métriques d'erreur pour le modèle retenu ($\beta = 0.8$)

Visualisation du lissage :

Les graphiques suivants illustrent l'apport de ce paramétrage. La courbe rouge (LES) traverse la série sans subir les à-coups, offrant une vision claire de la tendance.




Fig. 8 — Lissage efficace de la série CVS avec $\beta = 0.8$




Fig. 9 — Modèle final resaisonnalisé comparé aux données réelles

2.7 Calcul du LED

2.7.1 Modélisation par Lissage Exponentiel Double (LED)

Pour affiner notre prévision en tenant compte de la tendance baissière observée, nous avons utilisé la méthode du **Lissage Exponentiel Double**. Contrairement au lissage simple, cette approche applique deux fois le lissage successif pour estimer la pente locale de la série.

Cette méthode ne dépend que d'un seul paramètre de lissage, noté β .

2.7.1.1 Optimisation du paramètre β

Nous avons utilisé l’algorithme d’optimisation de la librairie sklearn pour trouver la valeur théorique de β qui minimise l’erreur (RMSE) sur notre jeu de données.

Parametre	Valeur
Beta	0.99
Erreur (RMSE)	3807.474

Tableau 5 — Paramètre optimal pour le modèle LED

Interprétation :

L’algorithme a convergé vers une valeur très élevée : $\beta = 0.99$. Dans notre formule de calcul, cela signifie que le modèle accorde **99% d’importance à l’historique** (la mémoire de la tendance) et seulement 1% aux variations instantanées. Ce choix traduit la volonté de l’algorithme de tracer une ligne de tendance très stable et rigide, ignorant totalement le « bruit » mensuel pour se concentrer sur la direction à long terme.

2.7.1.2 Visualisation graphique

Modélisation de la tendance (Sur série CVS) :

Le graphique ci-dessous montre l’application du LED (en rouge) sur la série désaisonnalisée (en gris). Grâce au β élevé (0.99), la courbe rouge est parfaitement lisse, quasi-linéaire, ce qui correspond bien à la tendance de fond décroissante que nous cherchions à isoler.




Fig. 10 — Estimation de la tendance par Lissage Double

Prévision finale (Resaisonnalisée) :

En réintégrant les coefficients saisonniers calculés précédemment, nous obtenons la courbe de prévision finale comparée aux données réelles.




Fig. 11 — Modèle LED confronté aux données réelles

Conclusion sur le modèle :

Le Lissage Exponentiel Double offre une image fidèle de la réalité. En combinant une tendance stable (gérée par le LED) et des variations cycliques fortes (gérées par les coefficients saisonniers), il parvient à suivre fidèlement la dynamique des mariages sur la décennie.

2.8 Ajustement par la méthode des Moindres Carrés

En complément des méthodes de lissage, nous avons réalisé un ajustement analytique pour modéliser la tendance de long terme par une droite. Cette approche, dite des « Moindres Carrés », cherche à minimiser la somme des carrés des écarts entre la droite de tendance et la série désaisonnalisée (CVS).

2.8.1 Équation et Paramètres du modèle

Le modèle de tendance est de la forme linéaire, s'exprimant ainsi :

$$\text{Tendance}_t = (\text{Pente} \times \text{Temps}) + \text{Niveau Initial}$$

Dans cette équation, la « **Pente** » détermine la direction et la vitesse de l'évolution (par exemple une baisse de 11 mariages/mois), tandis que le « **Niveau Initial** » fixe le point de départ théorique de la série.

Le tableau ci-dessous présente les paramètres calculés par régression linéaire sur la série CVS :

Parametre	Valeur
Pente (a)	-11.109
Ordonnée origine (b)	19458.536

Tableau 6 — Paramètres de la droite de tendance (Moindres Carrés)

Interprétation :

Le coefficient directeur négatif ($a \approx -11.1$) confirme mathématiquement la **tendance baisse sur le long terme** sur la période étudiée. En faisant abstraction des saisons, le nombre de mariages diminue en moyenne d'environ 11 unités chaque mois sur la période 2014-2023.

2.8.2 Analyse graphique

Visualisation de la tendance (Droite vs CVS) :

Le premier graphique ci-dessous superpose la série désaisonnalisée (en gris) et la droite de régression (en rouge). On constate que la droite traverse le nuage de points de manière équilibrée, capturant la direction générale sans se laisser influencer par les variations locales.




Fig. 12 — Ajustement linéaire de la tendance sur la série CVS

Modèle final (Resaisonnalisation) :

Pour obtenir les prévisions finales, nous avons multiplié les valeurs de cette droite par les coefficients saisonniers mensuels, selon la logique suivante :

$$\text{Prévision Finale}_t = [(\text{Pente} \times \text{Temps}) + \text{Niveau Initial}] \times \text{Saison}_t$$

Cette opération permet de « sculpter » la droite de tendance théorique en lui appliquant les variations habituelles du calendrier (creux en hiver, pics en été).

Le graphique suivant confronte ce modèle théorique aux données réelles :




Fig. 13 — *Modèle des Moindres Carrés resaisonnalisé vs Données réelles*

Conclusion sur la méthode :

Bien que ce modèle soit le plus rigide (il impose une décroissance constante), il offre une représentation très robuste. La combinaison de cette tendance linéaire et des coefficients saisonniers permet de reproduire fidèlement l'allure générale de la série, y compris l'amplitude des pics d'été qui diminue légèrement avec le temps (conséquence du modèle multiplicatif sur une tendance baissière).

3 Prédiction à partir des modèles

3.1 Prévisions 2024 : Modèle de Lissage Exponentiel Simple (LES)

Pour établir nos premières prévisions, nous avons exploité le modèle de Lissage Exponentiel Simple paramétré avec $\beta = 0.8$. Comme expliqué précédemment, ce choix d'un coefficient élevé (plutôt que l'optimum mathématique) nous permet de projeter un niveau moyen stable, débarrassé des anomalies ponctuelles de fin d'année.

3.1.1 Mécanisme de projection

Le modèle LES suppose que le niveau de la série reste constant dans le futur proche (pas de tendance haussière ou baissière intégrée). La base de nos calculs pour 2024 est donc le dernier niveau lissé enregistré en décembre 2023.

Parametre	Valeur
Alpha	0.8
Dernier Niveau (Lt)	19515.788

Tableau 7 — Paramètres de projection (Fin 2023)

3.1.2 Résultats des prévisions

Les prévisions mensuelles sont obtenues en multipliant ce niveau de base (≈ 19515) par les coefficients saisonniers de chaque mois. Le tableau ci-dessous présente les prédictions effectué.

	Pred_LES	Pred_Finale
2024-01-01	19515.788	6846.551
2024-02-01	19515.788	8770.112
2024-03-01	19515.788	9097.156
2024-04-01	19515.788	14093.827
2024-05-01	19515.788	21630.154
2024-06-01	19515.788	33232.42
2024-07-01	19515.788	35985.377
2024-08-01	19515.788	32429.937
2024-09-01	19515.788	32662.572
2024-10-01	19515.788	18734.041
2024-11-01	19515.788	9153.246
2024-12-01	19515.788	11554.064

Tableau 8 — Prédictions des mariages pour 2024

3.1.3 Analyse Graphique

Le graphique suivant permet de visualiser la jonction entre les données historiques (en gris) et notre prévision (en vert).




Fig. 14 — Projection 2024 avec le modèle LES ($\beta = 0.8$)

3.1.4 Critique du modèle :

On observe que la prévision reproduit parfaitement le cycle saisonnier habituel. Cependant, en raison de la nature du LES (tendance plate), le niveau moyen de 2024 reste identique à celui de fin 2023. Si la baisse continue des mariages (observée depuis 2014) se poursuit, ce modèle risque de **légèrement surestimer** la réalité.

3.2 Prévisions 2024 : Modèle de Lissage Exponentiel Double (LED)

Contrairement au modèle précédent qui figeait le niveau, le modèle LED est plus performant car il est capable de prolonger la dynamique de la série. Il suppose que la tendance observée récemment (baisse ou hausse) va continuer.

3.2.1 Mécanisme de projection

Pour construire ses prévisions, le modèle utilise deux indicateurs calculés à la fin de notre historique (Décembre 2023) :

- Le **Niveau Final** : Le point de départ de la prévision.
- La **Pente Finale** : La vitesse et la direction de l'évolution (par exemple, une baisse moyenne de x mariages par mois).

L'équation de prévision pour les mois futurs (h) s'écrit de manière explicite :

$$\text{Prévision Finale}_{t+h} = [\text{Niveau Final} + (h \times \text{Pente Finale})] \times \text{Coeff. Saisonnier}_{t+h}$$

Interprétation :

Le terme entre crochets tire une ligne droite qui prolonge la tendance actuelle vers le futur. Ensuite, nous multiplions ce résultat par la saisonnalité pour redonner à la courbe ses variations cycliques habituelles (les creux et les pics de l'année).

Parametre	Valeur
Niveau final (b)	18745.006
Pente finale (a)	3.979

Tableau 9 — Paramètres de tendance pour la projection 2024

3.2.2 Résultats des prévisions

Contrairement à la tendance globale décennale qui était baissière, le modèle LED a capté une légère dynamique positive sur les tout derniers mois de 2023 (pente de +3.98 mariages/mois). Il projette donc une année 2024 en très légère croissance par rapport au niveau de fin 2023.

	Pred_LED	Pred_Finale
2024-01-01	18748.985	6577.54
2024-02-01	18752.964	8427.309
2024-03-01	18756.942	8743.425
2024-04-01	18760.921	13548.681
2024-05-01	18764.9	20797.914
2024-06-01	18768.878	31960.547
2024-07-01	18772.857	34615.478
2024-08-01	18776.836	31201.999
2024-09-01	18780.814	31432.484
2024-10-01	18784.793	18032.328
2024-11-01	18788.772	8812.263
2024-12-01	18792.751	11125.999

Tableau 10 — Prédictions LED pour 2024

3.2.3 Analyse Graphique

Le graphique suivant montre la trajectoire prévue par le LED.




Fig. 15 — Projection 2024 avec le modèle LED (Tendance ajustée)

3.2.4 Critique du modèle :

Ce modèle est plus réactif que les autres. Alors que la régression linéaire « voit » une baisse continue sur 10 ans, le LED « sent » que la chute s’est peut-être arrêtée récemment et propose une stabilisation, voire une infime reprise. C’est potentiellement le scénario le plus réaliste si l’on considère que la baisse post-COVID a fini par toucher un plancher.

3.3 Prévisions 2024 : Méthode des Moindres Carrés (Tendance Linéaire)

Cette approche est celle qui vise le long terme. Elle ne tient pas compte des fluctuations récentes (comme le LED) ni du dernier niveau connu (comme le LES), mais prolonge mécaniquement la tendance moyenne observée sur les 10 dernières années.

3.3.1 Mécanisme de projection (Moindres Carrés)

La prévision repose sur l’extrapolation mécanique de la droite de régression linéaire calculée sur l’historique. Pour chaque mois futur, nous appliquons la formule suivante :

$$\text{Prévision Finale}_t = [(\text{Pente} \times \text{Temps}) + \text{Niveau Initial}] \times \text{Coeff. Saisonnier}_t$$

Application numérique :

Dans notre cas, nous utilisons les paramètres de la tendance de fond estimés précédemment :

- La **Pente** ($a = -11.11$) indique une baisse régulière d’environ 11 mariages par mois.
- Le **Niveau Initial** ($b = 19458$) sert de point d’ancrage à l’origine de la série.

3.3.2 Résultats des prévisions

Le modèle anticipe une poursuite de l'érosion lente du nombre de mariages. Le niveau « désaisonnalisé » pour 2024 tourne autour de 18 000 mariages/mois, sur lequel s'applique la forte saisonnalité.

	Pred_Tendance	Pred_Finale
2024-01-01	18114.343	6354.894
2024-02-01	18103.234	8135.33
2024-03-01	18092.125	8433.525
2024-04-01	18081.016	13057.67
2024-05-01	18069.907	20027.624
2024-06-01	18058.798	30751.388
2024-07-01	18047.689	33278.332
2024-08-01	18036.58	29971.895
2024-09-01	18025.471	30168.305
2024-10-01	18014.362	17292.758
2024-11-01	18003.253	8443.84
2024-12-01	17992.144	10652.01

Tableau 11 — Prévisions 2024 basées sur la tendance décennale

3.3.3 Analyse Graphique

Le graphique ci-dessous illustre cette trajectoire. On remarque que la prévision (en vert) s'inscrit dans la continuité parfaite de la direction générale de la courbe grise, ignorant les fluctuations récentes.




Fig. 16 — Projection de la tendance linéaire pour 2024

3.3.4 Critique du modèle :

C'est le modèle le plus conservateur. Il suppose que la baisse continue observée depuis 10 ans va se poursuivre.

- Par rapport au LES (qui prévoyait 33 600 en juillet), ce modèle est plus pessimiste (31 000).
- Il risque de sous-estimer la réalité si une stabilisation du marché matrimonial s'est opérée ces deux dernières années.

3.4 Synthèse et comparaison des modèles de prévision

Pour conclure cette première partie, nous avons superposé les résultats de nos trois approches (Lissage Simple, Lissage Double, Moindres Carrés) afin d'identifier les zones de convergence et de divergence pour l'année 2024.

3.4.1 Analyse visuelle comparative

Le graphique ci-dessous rassemble les trois courbes de prévision ainsi que l'historique récent (2023).




Fig. 17 – Confrontation des scénarios de prévision pour 2024

On observe une **synchronisation parfaite de la saisonnalité** sur tous les modèles. En revanche, une divergence apparaît sur l’amplitude du pic estival :

- Les courbes du **LES (Simple)** et du **LED (Double)** sont extrêmement proches et se situent dans la fourchette haute.
- La courbe des **Moindres Carrés** se détache vers le bas, prévoyant un volume de mariages inférieur.

3.4.2 Comparaison quantitative (Le « Pic » de Juillet)

Pour illustrer ces écarts, comparons les prévisions pour le mois le plus important de l’année, juillet 2024 :

Modèle	Prévision Juillet 2024	Interprétation
LES ($\beta = 0.8$)	35 985	Scénario Optimiste
Moindres Carrés	33 278	Scénario Tendanciel
LED ($\beta = 0.99$)	35 995	Scénario Prudent

Tableau 12 – Écart de prévisions pour le pic d’activité

3.4.3 Discussion et Choix du modèle

L’analyse des chiffres révèle une configuration intéressante :

- Convergence LES / LED : Les deux méthodes de lissage (Simple et Double) aboutissent à des résultats quasi-identiques pour le pic de juillet (environ **36 000 mariages**). Cela indique que la dynamique récente (sur laquelle se basent ces modèles avec des bêtas élevés) est plutôt favorable.
- L'écart des Moindres Carrés : Ce modèle est le seul à projeter une valeur nettement plus faible (**33 278**). Cela s'explique par sa construction : Il se base sur la baisse continue des 10 dernières années, ce qui rend la prévision plus pessimiste.

L'écart entre le scénario haut (LED/LES) et le scénario bas (Moindres Carrés) est d'environ **2 700 mariages**, ce qui représente une incertitude notable.

3.4.4 Conclusion :

Au vu de ces résultats, nous pouvons établir une fourchette de prévision pour le pic de l'été 2024 comprise entre 33 300 et 36 000 mariages.

Si la dynamique observée fin 2023 se confirme, les modèles de lissage (LES/LED) semblent les plus pertinents. En revanche, si la tendance lourde de la décennie reprend ses droits, le scénario des Moindres Carrés constituera un plancher plus réaliste.

I 4 Partie 2 : Étude du modèle ARIMA

Dans cette seconde partie, nous abordons la modélisation stochastique en utilisant l'approche ARIMA (**AutoRegressive Integrated Moving Average**). Contrairement aux méthodes de lissage précédentes, l'objectif est ici de capturer la structure de corrélation interne des données (l'inertie de la série) pour effectuer des prévisions.

4.1 Analyse de la stationnarité et Différenciation

La condition préalable à la modélisation ARIMA est la stationnarité de la série (propriétés statistiques constantes : moyenne et variance stables dans le temps).

4.1.1 Test de Dickey-Fuller Augmenté (ADF)

Nous avons utilisé le test statistique ADF pour vérifier formellement cette propriété.

- **Hypothèse nulle (H_0)** : La série possède une racine unitaire (elle n'est pas stationnaire).
- **Règle de décision** : Si la p -value < 0.05 , on rejette H_0 et la série est considérée comme stationnaire.

Résultat : Sur la série brute, le test a renvoyé une p -value > 0.05 . Nous ne pouvons pas rejeter l'hypothèse nulle : la série d'origine n'est pas stationnaire (présence de tendance et saisonnalité).

4.1.2 Différenciation de la série (d)

Pour stationnariser la série, nous avons appliqué une différenciation d'ordre 1 ($d = 1$). Cela revient à travailler sur les variations mensuelles : $Y'_t = Y_t - Y_{t-1}$.

Vérification : L'analyse des graphiques d'autocorrélation (ACF) sur la série différenciée montre une décroissance rapide des corrélations vers zéro, ce qui est caractéristique d'un processus stationnaire. Nous fixons donc le paramètre d'intégration à $d = 1$.

4.2 Identification des ordres (p et q)

Une fois la série rendue stationnaire, nous devons déterminer les ordres des processus AutoRégressif (p) et Moyenne Mobile (q). Pour cela, nous analysons les corrélogrammes :

- **PACF (Autocorrélation Partielle) → Choix de p :** Nous observons un **pic significatif au lag 1**, suivi d'une coupure nette. Cela suggère un processus autorégressif d'ordre 1. Nous retenons $p = 1$.
- **ACF (Autocorrélation Simple) → Choix de q :** Nous observons des **pics significatifs aux lags 1 et 2**. Cela indique une possible composante de moyenne mobile d'ordre 1 ou 2. Nous devons donc tester les valeurs $q = 1$ et $q = 2$.

Cette analyse structurelle nous conduit à mettre en compétition deux modèles candidats :

1. **ARIMA (1, 1, 1)**
2. **ARIMA (1, 1, 2)**

4.3 Estimation et Sélection du meilleur modèle

Nous avons estimé les paramètres de ces deux modèles par le maximum de vraisemblance. Le tableau ci-dessous compare leurs performances :

Critère	ARIMA (1,1,1)	ARIMA (1,1,2)	Interprétation
AIC (Akaike)	855.524	857.140	Plus bas = Mieux
BIC (Bayesian)	865.463	870.393	Plus bas = Mieux
Nb Paramètres	3	4	Complexité minimale
Sigma ² (σ^2)	3.8327	3.8259	Variance quasi-identique

Tableau 13 — Comparaison des critères d'information (AIC/BIC)

4.3.1 Analyse détaillée et Choix définitif

Le modèle **ARIMA (1,1,1)** s'impose comme le meilleur choix pour trois raisons statistiques majeures :

1. **Minimisation de l'Information (AIC/BIC) :** L'AIC (855.52) et le BIC (865.46) sont strictement inférieurs pour le modèle (1,1,1). Ces critères pénalisant la complexité du modèle, un score plus bas indique un meilleur compromis entre la qualité de l'ajustement et le nombre de paramètres.
2. **Non-significativité du paramètre $ma.L2$:** L'analyse des coefficients du modèle ARIMA (1,1,2) révèle que le paramètre supplémentaire associé au deuxième retard de moyenne mobile ($ma.L2$) possède une **p-value de 0.722**. Cette valeur étant très supérieure au seuil de risque $\alpha = 0.05$, nous concluons que ce coefficient n'est pas statistiquement différent de zéro. L'ajout de $q = 2$ n'apporte donc aucune information utile au modèle.
3. **Principe de Complexité minimale :** Puisque la variance résiduelle ($\sigma^2 \approx 3.83$) est quasiment identique entre les deux modèles, il est impératif de choisir le modèle le plus simple (3 paramètres au lieu de 4) pour éviter le sur-apprentissage (**overfitting**).

4.4 Validation du Modèle ARIMA (1,1,1)

4.4.1 Comparaison graphique des prédictions

Le graphique ci-dessous superpose les prévisions des deux modèles aux données réelles.




Fig. 18 — *Superposition des prédictions : les deux modèles sont quasi-indiscernables*

La superposition quasi-parfaite des courbes rouge (ARIMA 1,1,1) et verte (ARIMA 1,1,2) confirme visuellement que la complexité ajoutée par le modèle (1,1,2) est superflue.

4.4.2 Analyse des résidus (Diagnostic final)

Pour valider définitivement le modèle retenu, nous devons nous assurer que les résidus (erreurs du modèle) se comportent comme un **bruit blanc** :

- **Absence d'autocorrélation** : Le test de **Ljung-Box** renvoie une **p-value de 0.40** (largement supérieure à 0.05). Cela confirme qu'il ne reste aucune corrélation significative dans les résidus : le modèle a capturé toute la dynamique temporelle exploitable.
- **Distribution** : L'histogramme des résidus montre une distribution centrée sur zéro et d'allure gaussienne (normale), validant les hypothèses du modèle.

4.5 Conclusion Générale

L'étude rigoureuse de la série (différenciation, analyse des corrélogrammes et critères d'information) nous conduit à retenir sans ambiguïté le modèle **ARIMA (1,1,1)**.

Ce modèle est statistiquement robuste, respecte le principe de Complexité minimale et présente des résidus sains (bruit blanc), ce qui en fait un outil fiable pour la prévision.